

Contexto, Objetivo e Hipóteses

- Contexto: . O diabetes mellitus é uma das doenças crônicas que mais cresce globalmente, representando um desafio crítico para os sistemas de saúde pública devido ao alto custo das complicações de longo prazo e à subnotificação de casos iniciais. Este projeto utiliza o dataset Diabetes Health Indicators do CDC, uma base de dados robusta com mais de 250 mil registros que traduzem o perfil de saúde, estilo de vida e indicadores socioeconômicos da população. A aplicação de Machine Learning neste contexto visa transformar dados brutos em uma ferramenta de triagem capaz de identificar indivíduos em risco antes do agravamento do quadro clínico. - Objetivos: . Desenvolver um modelo preditivo: Criar e calibrar um algoritmo de classificação para estimar a probabilidade de um indivíduo possuir diabetes; . Priorizar a detecção precoce (Recall): Implementar uma estratégia de decisão baseada em um threshold clínico de 0,25 para garantir que a vasta maioria dos casos positivos seja identificada; . Promover a interpretabilidade: Utilizar técnicas de SHAP para explicar os fatores de risco individuais, permitindo que a decisão do modelo seja transparente e clinicamente aceitável. . Viabilizar o acesso: Realizar o deploy do modelo em uma aplicação interativa (Streamlit) para uso prático em triagens preliminares. - Hipóteses: Com base na literatura médica e na análise exploratória inicial (EDA), foram estabelecidas as seguintes hipóteses: . H1 (Fatores Metabólicos): O Índice de Massa Corporal (IMC) e a pressão arterial elevada são os preditores individuais mais fortes para o risco de diabetes; . H2 (Percepção de Saúde): A autopercepção de saúde do paciente (GenHlth) possui uma correlação direta e significativa com o diagnóstico real, servindo como um indicador confiável para o modelo; . H3 (Sinergia de Risco): A combinação de comorbidades (como doenças cardíacas ou AVC prévio) e idade avançada potencializa exponencialmente a probabilidade de diabetes em comparação a fatores isolados; . H4 (Estilo de Vida): Variáveis como consumo regular de frutas e vegetais e a prática de atividade física atuam como fatores de proteção moderados, reduzindo o impacto negativo de outros preditores;

Carregamento de Dados e Entendimento Inicial dos Dados

- Carregamento das bibliotecas e dados

```
In [4]: # =====
# 1. Padrão e Visualização
# =====

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import shap
import warnings

warnings.filterwarnings("ignore")
# Para visualização do SHAP no notebook

# =====
# 2. Estatística e Matemática
# =====

from scipy import stats
from scipy.stats import chi2_contingency

# =====
# 3. Pré-processamento e Transformação
# =====

from sklearn.preprocessing import (
    OneHotEncoder,
```

```

        StandardScaler,
        LabelEncoder,
    )
    from sklearn.compose import ColumnTransformer
    from sklearn.pipeline import Pipeline
    from sklearn.utils.class_weight import compute_sample_weight
    from tempfile import mkdtemp

    # =====
    # 4. Modelagem e Seleção
    # =====
    from sklearn.model_selection import train_test_split, RandomizedSearchCV
    from sklearn.feature_selection import SelectKBest, mutual_info_classif

    # =====
    # 5. Algoritmos de Classificação
    # =====
    from sklearn.dummy import DummyClassifier
    from sklearn.linear_model import LogisticRegression
    from sklearn.ensemble import RandomForestClassifier
    from xgboost import XGBClassifier
    from lightgbm import LGBMClassifier

    # =====
    # 6. Métricas de Avaliação
    # =====
    from sklearn.metrics import (
        f1_score,
        average_precision_score,
        recall_score,
        roc_auc_score,
        roc_curve,
        classification_report,
        confusion_matrix,
        ConfusionMatrixDisplay,
        brier_score_loss,
        precision_recall_curve
    )

    from sklearn.calibration import calibration_curve

    # =====
    # 7. Produção/Exportação
    # =====
    import joblib

    # =====
    # 8. Repositório UCI
    # =====
    from ucimlrepo import fetch_ucirepo

```

```

In [5]: # Dataset
cdc_diabetes_health_indicators = fetch_ucirepo(id=891)

X = cdc_diabetes_health_indicators.data.features
y = cdc_diabetes_health_indicators.data.targets

```

```
df = pd.concat([X,y], axis = 1)
df.head()
```

```
Out[5]:
```

	HighBP	HighChol	CholCheck	BMI	Smoker	Stroke	HeartDiseaseorAttack	PhysActivit
0	1	1	1	40	1	0	0	
1	0	0	0	25	1	0	0	
2	1	1	1	28	0	0	0	
3	1	0	1	27	0	0	0	
4	1	1	1	24	0	0	0	

5 rows × 22 columns

- Entendimento inicial

```
In [6]: linhas, colunas = df.shape
print(f"Lines: {linhas}, columns: {colunas}")
```

Lines: 253680, columns: 22

```
In [9]: df.dtypes
```

```
Out[9]: HighBP          int64
HighChol          int64
CholCheck          int64
BMI                int64
Smoker             int64
Stroke             int64
HeartDiseaseorAttack int64
PhysActivity       int64
Fruits             int64
Veggies            int64
HvyAlcoholConsump  int64
AnyHealthcare      int64
NoDocbcCost        int64
GenHlth            int64
MentHlth           int64
PhysHlth           int64
DiffWalk           int64
Sex                int64
Age                int64
Education          int64
Income             int64
Diabetes_binary    int64
dtype: object
```

```
In [10]: print("No null values in the dataset")
print('-'*30)
df.isna().sum()
```

No null values in the dataset

```
Out[10]: HighBP          0
         HighChol       0
         CholCheck      0
         BMI            0
         Smoker         0
         Stroke         0
         HeartDiseaseorAttack 0
         PhysActivity    0
         Fruits         0
         Veggies        0
         HvyAlcoholConsump 0
         AnyHealthcare  0
         NoDocbcCost    0
         GenHlth        0
         MenthHlth      0
         PhysHlth       0
         DiffWalk       0
         Sex            0
         Age            0
         Education      0
         Income         0
         Diabetes_binary 0
         dtype: int64
```

```
In [11]: print(f"Duplicated values: {df.duplicated().sum()}")
         df = df.drop_duplicates()
         print(f"Duplicated values now: {df.duplicated().sum()}")
```

```
Duplicated values: 24206
Duplicated values now: 0
```

```
In [12]: # Detectar "missing values" disfarçados
         # Valores que representam "não respondeu" ou "não aplicável"
         missing_values = [-1, -2]

         df = df.replace(missing_values, np.nan)
         df.isna().sum()
```

```
Out[12]: HighBP          0
         HighChol       0
         CholCheck      0
         BMI            0
         Smoker         0
         Stroke         0
         HeartDiseaseorAttack 0
         PhysActivity    0
         Fruits         0
         Veggies        0
         HvyAlcoholConsump 0
         AnyHealthcare   0
         NoDocbcCost     0
         GenHlth        0
         MentHlth       0
         PhysHlth       0
         DiffWalk       0
         Sex            0
         Age            0
         Education      0
         Income         0
         Diabetes_binary 0
         dtype: int64
```

- Classificação das variáveis

```
In [13]: cols_bin = ["HighBP", "HighChol", "CholCheck", "Smoker", "Stroke", "HeartDiseaseorA",
                    "Fruits", "Veggies", "HvyAlcoholConsump", "AnyHealthcare", "NoDocbcCost"]

         cols_ordinal = ["GenHlth", "Education"]

         cols_semiar = ["Age", "Income"] # ambas são ordinais-não linear. O uso de One-Hot p

         cols_numeric = ["BMI", "MentHlth", "PhysHlth"]

         target = "Diabetes_binary"
```

- Identificação prévia de possíveis problemas

- Data leakage: . Se y = "Diabetes_binary", "MentHlth" (dias de saúde mental ruim nos últimos 30 dias) "PhysHlth" (dias de saúde física ruim nos últimos 30 dias) são potenciais problemas já que essas variáveis contêm consequências diretas de diabetes. É recomendável removê-las. - Tipos errados (datas como string): . Tudo ok. - Variáveis com significado especial: . "HighBP", "HighChol", "CholCheck", "Smoker", "Stroke", "HeartDiseaseorAttack", "PhysActivity", "Fruits", "Veggies", "HvyAlcoholConsump", "AnyHealthcare", "NoDocbcCost", "DiffWalk" e "Sex" são binárias. - Variáveis derivadas do target: . Não há Função direta de Diabetes_binary ou construída a partir de dados futuros ou um componente matemático do target.

Análise Exploratória

- A etapa de análise exploratória permitiu compreender a distribuição das variáveis e identificar os perfis de risco mais acentuados no dataset do CDC, que conta com um volume robusto de 253.680 registros e 22 colunas iniciais. - Distribuição da Variável Target: Observou-se um forte desequilíbrio de classe na variável Diabetes_binary. A classe minoritária (indivíduos com diabetes) representa pouco mais de 15% dos dados. Esse fator foi determinante para a escolha de métricas de avaliação focadas em dados desbalanceados, como o Average Precision e o Recall. - Relações de Risco e Heatmaps Metabólicos: Através de cruzamentos de

dados via tabelas dinâmicas e mapas de calor, identificamos padrões críticos: . Fatores Combinados: Indivíduos com maior IMC e que já possuem pressão alta ou colesterol alto apresentam, em média, a maior incidência de casos de diabetes; . Perfil por Gênero: Indivíduos do gênero feminino com maior IMC e que praticaram atividade física nos últimos 30 dias figuram entre os perfis com mais casos registrados, indicando que a atividade física isolada pode não compensar o risco metabólico de um IMC elevado. - Variáveis Binárias e Estilo de Vida: A análise de proporções condicionais revelou que: . Preditores Fortes: Ter tido um AVC ou possuir doença arterial coronariana (infarto) está fortemente associado a casos de diabetes; . Autopercepção de Saúde: Existe uma correlação visual clara onde indivíduos que classificam sua saúde como "Ruim" ou "Regular" (níveis 4 e 5) estão massivamente mais associados à presença da doença em comparação aos que se sentem "Excelentes". - Análise de Correlação e Multicolinearidade: Utilizou-se o teste V de Cramér para avaliar a associação entre variáveis categóricas. Identificou-se uma associação moderada (0.49) entre GenHlth e DiffWalk, indicando que a percepção de saúde ruim está intimamente ligada à dificuldade de locomoção. A correlação linear entre as variáveis numéricas, como o IMC e dias de saúde mental/física ruim, mostrou-se fraca, justificando o uso de modelos de árvores que capturam relações não-lineares complexas.

- Dataset EDA

```
In [14]: df_eda = df.copy()
```

- Heatmap gênero x diabetes nos ultimos 30 dias (IMC)


- Indivíduos do gênero feminino com maior IMC, em média, são aqueles com mais casos de diabetes.

```
In [179]: # 0 = female, 1 = male
# physical activity in past 30 days - not including job 0 = no 1 = yes

pivot = df_eda.pivot_table(
    values="BMI",
    index="Diabetes_binary",
    columns="Sex",
    aggfunc="mean"
)

plt.figure(figsize=(14,6))
sns.heatmap(
    pivot,
    cmap="viridis",
    linewidths=0.1,
    linecolor="gray"
)

plt.title("Heatmap: BMI - Sex x Diabetes_binary", fontsize=14)
plt.xlabel("Sex")
plt.ylabel("Diabetes_binary")
plt.show()
```




- Heatmap pressão alta x diabetes (IMC)

- Indivíduos com maior IMC e pressão alta são aqueles que, em média, apresentam maiores casos de diabetes.

```
In [15]: pivot = df_eda.pivot_table(
    values="BMI",
    index="Diabetes_binary",
    columns="HighBP",
    aggfunc="mean"
)

plt.figure(figsize=(14,6))
sns.heatmap(
    pivot,
    cmap="viridis",
    linewidths=0.1,
    linecolor="gray"
)

plt.title("Heatmap: BMI — HighBP x Diabetes_binary", fontsize=14)
plt.xlabel("HighBP")
plt.ylabel("Diabetes_binary")
plt.show()
```




- Heatmap colesterol x diabetes (IMC)

- Indivíduos com maior IMC e que têm colesterol alto são aqueles que, em média, estão mais associados a quadros de diabetes.

```
In [16]: pivot = df_eda.pivot_table(
    values="BMI",
    index="Diabetes_binary",
    columns="HighChol",
    aggfunc="mean"
)

plt.figure(figsize=(14,6))
sns.heatmap(
    pivot,
    cmap="viridis",
    linewidths=0.1,
    linecolor="gray"
)

plt.title("Heatmap: BMI — HighBP x Diabetes_binary", fontsize=14)
plt.xlabel("HighChol")
plt.ylabel("Diabetes_binary")
plt.show()
```


- Distribuição da variável target

- Há desequilíbrio de classe. A classe minoritária (1) representa algo próximo de 15% dos dados.

```
In [17]: plt.figure(figsize=(12,5))
sns.countplot(data=df_eda, x=target,
              stat="percent", edgecolor="black")

plt.title(f"Countplot - {target}")

plt.tight_layout()
plt.show()
```



- Distribuição das variáveis binárias

- As variáveis mais equilibradas são "HighBP", "HighCol", "Smoker".

```
In [18]: fig, axes = plt.subplots(7, 2, figsize=(25, 20))
axes = axes.flatten()
```


```

for ax, col in zip(axes, cols_bin):
    sns.countplot(
        data=df_eda,
        x=col,
        edgecolor="black",
        stat="percent",
        ax=ax
    )
    ax.set_title(f"Countplot - {col}", fontsize=20)
    ax.set_xlabel(col, fontsize=16)
    ax.set_ylabel("Percent", fontsize=16)
    ax.grid(axis="y", linestyle="--", alpha=0.5)
    ax.tick_params("x", labels=15)
    ax.tick_params("y", labels=15)

# Caso tenha mais axes do que colunas numéricas
for ax in axes[len(cols_bin):]:
    fig.delaxes(ax)

plt.tight_layout()
plt.show()

```



- Distribuição das variáveis ordinais


- Há um desequilíbrio notório na classe minoritária (5) de "GenHlth" e nas minoritárias (1, 2, 3) de "Education".

```
In [19]: fig, axes = plt.subplots(1, 2, figsize=(12, 5))
axes = axes.flatten()

for ax, col in zip(axes, cols_ordinal):
    sns.countplot(
        data=df_eda,
        x=col,
        edgecolor="black",
        stat="percent",
        ax=ax
    )
    ax.set_title(f"Countplot - {col}")
    ax.set_xlabel(col)
    ax.set_ylabel("Percent")
    ax.grid(axis="y", linestyle="--", alpha=0.5)
    ax.tick_params("x")
    ax.tick_params("y")

# Caso tenha mais eixos do que colunas numéricas
for ax in axes[len(cols_ordinal):]:
    fig.delaxes(ax)

plt.tight_layout()
plt.show()
```



- Distribuição das variáveis semiordinárias

- A classe menos representada em "Age" (1) contém apenas um pouco mais de 2% de registros. Já em "Income", (1) tem menos de 5%.

```
In [20]: fig, axes = plt.subplots(1, 2, figsize=(12, 5))
axes = axes.flatten()

for ax, col in zip(axes, cols_semior):
    sns.countplot(
        data=df_eda,
        x=col,
        edgecolor="black",
        stat="percent",
        ax=ax
    )
```


```

)
ax.set_title(f"Countplot - {col}")
ax.set_xlabel(col)
ax.set_ylabel("Percent")
ax.grid(axis="y", linestyle="--", alpha=0.5)
ax.tick_params("x")
ax.tick_params("y")

# Caso tenha mais axes do que colunas numéricas
for ax in axes[len(cols_senior):]:
    fig.delaxes(ax)

plt.tight_layout()
plt.show()

```



- Distribuição das variáveis numéricas

- Ambas as variáveis têm natureza discreta. Adicionalmente, ambas contam com uma presença considerável de outliers.

```


In [21]: fig, axes = plt.subplots(1, 2, figsize=(12, 5))
axes = axes.flatten()

for ax, col in zip(axes, cols_numeric):
    sns.histplot(
        data=df_eda,
        x=col,
        kde=True,
        edgecolor="black",
        ax=ax
    )
    ax.set_title(f"Histogram - {col}")
    ax.set_xlabel(col)
    ax.set_ylabel("Frequência")
    ax.grid(axis="y", linestyle="--", alpha=0.5)

# Caso tenha mais axes do que colunas numéricas
for ax in axes[len(cols_numeric):]:
    fig.delaxes(ax)

```

```
plt.tight_layout()
plt.show()
```




```
In [22]: fig, axes = plt.subplots(1, 2, figsize=(12, 5))
         axes = axes.flatten()

         for ax, col in zip(axes, cols_numeric):
             sns.boxplot(
                 data=df_eda,
                 x=col,
                 ax=ax
             )
             ax.set_title(f"Boxplot {col}")
             ax.set_xlabel(col)
             ax.set_ylabel("Medidas")
             ax.grid(axis="y", linestyle="--", alpha=0.5)

         # Caso tenha mais axes do que colunas numéricas
         for ax in axes[len(cols_numeric):]:
             fig.delaxes(ax)

         plt.tight_layout()
         plt.show()
```



- Relação da variável target com as variáveis binárias

- Insights (na média, não determinístico): . Indivíduos com pressão alta estão mais associados a casos de diabetes; . Indivíduos com colesterol alto estão mais associados a casos de diabetes; . Indivíduos que fizeram checkagem de colesterol estão mais associados a casos de diabetes; . Indivíduos fumantes e não fumantes estão associados a um número equiparável de casos de diabetes; . Indivíduos que tiveram AVC estão mais associados a casos de diabetes; . Indivíduos que apresentam doença arterial coronariana ou ou infarto do miocárdio estão mais associados a casos de diabetes; . Indivíduos que não praticaram atividade física nos últimos 30 dias estão mais associados a casos de diabetes; . Indivíduos que consomem ou não consomem 1 ou mais frutas por dia estão associados a um número equiparável de casos de diabetes; . Indivíduos que não consomem 1 ou mais verduras por dia estão mais associados a casos de diabetes; . Indivíduos que não são alcoolatras (homens adultos que consomem mais de 14 doses por semana e mulheres adultas que consomem mais de 7 doses por semana) estão associados a maiores casos de diabetes; . Indivíduos que tem alguma cobertura de saúde estão mais associados a casos de diabetes; . Indivíduos que precisaram e os que não precisaram de consulta médica no último ano (mas não puderam devido ao custo), estão associados a um número equiparável de casos de diabetes; . Indivíduos que apresentam dificuldade de andar ou subir escadas estão mais associados a casos de diabetes; . Indivíduos do sexo masculino e feminino estão associados a um número equiparável de casos de diabetes.

```
In [24]: fig, axes = plt.subplots(7, 2, figsize=(30, 25))
axes = axes.flatten()

for ax, col in zip(axes, cols_bin):


    # Tabela de proporções condicionais
    prop = (
        df_eda
        .groupby(col)[target]
        .value_counts(normalize=True)
        .rename("proportion")
        .reset_index()
    )

    sns.barplot(
        data=prop,
        x=col,
        y="proportion",
        hue=target,
        palette="viridis",
        ax=ax,
        edgecolor="black"
    )

    ax.set_title(f"Proportion of {target} by {col}", fontsize=20)
    ax.set_xlabel(col, fontsize=16)
    ax.set_ylabel("Conditional Proportion", fontsize=16)
    ax.set_ylim(0, 1)
    ax.grid(axis="y", linestyle="--", alpha=0.5)
    ax.tick_params("x", labelsize=15)
    ax.tick_params("y", labelsize=15)

    # Remover axes excedentes
    for ax in axes[len(cols_bin):]:
        fig.delaxes(ax)

plt.tight_layout()
plt.show()
```



- Relação da variável target com as variáveis ordinais

- Insights(na média, não determinístico): . Os indivíduos que afirmam que sua saúde é ruim estão mais associados a casos de diabetes; . Os indivíduos que cursaram apenas do 1º ao 8º ano (Ensino Fundamental) estão mais associados a casos de diabetes.

```
In [25]: fig, axes = plt.subplots(1, 2, figsize=(12, 5))
axes = axes.flatten()

for ax, col in zip(axes, cols_ordinal):

    # Tabela de proporções condicionais
    prop = (
        df_eda
        .groupby(col)[target]
        .value_counts(normalize=True)
        .rename("proportion")
        .reset_index()
    )

    sns.barplot(
        data=prop,
        x=col,
        y="proportion",
        hue=target,
        palette="viridis",
```

```


        ax=ax,
        edgecolor="black"
    )

    ax.set_title(f"Proportion of {target} by {col}")
    ax.set_xlabel(col)
    ax.set_ylabel("Conditional Proportion")
    ax.set_ylim(0, 1)
    ax.grid(axis="y", linestyle="--", alpha=0.5)
    ax.tick_params("x")
    ax.tick_params("y")

# Remover axes excedentes
for ax in axes[len(cols_ordinal):]:
    fig.delaxes(ax)

plt.tight_layout()
plt.show()

```



- Relação da variável target com as variáveis semiordinais

- Insights(na média, não determinístico): . Os indivíduos da faixa etária 11 estão associados a mais casos de diabetes; . Os indivíduos da faixa de renda 2 estão associados a mais casos de diabetes.

```

In [26]: fig, axes = plt.subplots(1, 2, figsize=(12, 5))
         axes = axes.flatten()

         for ax, col in zip(axes, cols_semior):

             # Tabela de proporções condicionais
             prop = (
                 df_eda
                 .groupby(col)[target]
                 .value_counts(normalize=True)
                 .rename("proportion")
                 .reset_index()
             )

             sns.barplot(
                 data=prop,

```



```


x=col,
y="proportion",
hue=target,
palette="viridis",
ax=ax,
edgecolor="black"
)

ax.set_title(f"Proportion of {target} by {col}")
ax.set_xlabel(col)
ax.set_ylabel("Condiciona! Proportion")
ax.set_ylim(0, 1)
ax.grid(axis="y", linestyle="--", alpha=0.5)
ax.tick_params("x")
ax.tick_params("y")

# Remover axes excedentes
for ax in axes[len(cols_semiar):]:
    fig.delaxes(ax)

plt.tight_layout()
plt.show()

```



- Relação da variável target com as variáveis numéricas

- Somente a variável "PhyHith" para indivíduos com diabetes não há outliers.

```

In [27]: fig, axes = plt.subplots(2, 2, figsize=(12, 10))
axes = axes.flatten()

for ax, col in zip(axes, cols_numeric):

    # Boxplot estratificado
    sns.boxplot(
        data=df_eda,
        x=target,
        y=col,
        palette="viridis",
        ax=ax
    )

```

```

# Contagem por classe (ordenada)
counts = df_eda[target].value_counts().sort_index()

# Limites atuais do eixo Y
ymin, ymax = ax.get_ylim()
y_range = ymax - ymin

# Offset para posicionar o texto fora da área dos dados
offset = 0.10 * y_range

# Inserir n abaixo de cada categoria
for i, cls in enumerate(counts.index):
    ax.text(
        i,
        ymin - offset,
        f"n={counts[cls]}",
        ha="center",
        va="top",
        fontsize=9
    )


# Expandir o eixo Y inferior para não cortar o texto
ax.set_ylim(ymin - 1.5 * offset, ymax)

# Ajustes visuais
ax.set_title(f"Distribution of {col} by {target}")
ax.set_xlabel(target)
ax.set_ylabel(col)
ax.grid(axis="y", linestyle="--", alpha=0.5)

# Remover axes extras, se houver
for ax in axes[len(cols_numeric):]:
    fig.delaxes(ax)

plt.tight_layout()
plt.show()


```



- Correlação

- A correlação linear entre as variáveis não é forte.

```
In [28]: corr = df[cols_numeric].corr()
plt.figure(figsize=(12,5))
plt.title("Correlation Matrix")
sns.heatmap(corr, vmax=1, annot=True, square=True, cmap="Blues");
```



- Associação (categórica vs categórica)

Valor do V de Cramér Interpretação da Associação Comentário de Negócio -----
 ----- 0.00 a 0.10 Desprezível / Nula A variável não ajuda a distinguir as classes. Ruído. 0.10 a 0.30 Fraca Existe um sinal leve, mas sozinha a variável não decide nada. Útil em conjunto com outras. 0.30 a 0.50 Moderada Associação Importante. Esta variável já tem poder preditivo relevante. > 0.50 Forte Determinante. A variável quase "define" o resultado. (Raro em dados sociais/humanos).- A associação entre "GenHlth" e "DriftWalk" tem força moderada (0.49), quase determinante.

```
In [29]: def cramers_v_corrected(confusion_matrix):
    chi2 = stats.chi2_contingency(confusion_matrix)[0]
    n = confusion_matrix.sum().sum()
    phi2 = chi2 / n
    r, k = confusion_matrix.shape

    # Correction
    phi2corr = max(0, phi2 - ((k - 1)*(r - 1))/(n - 1))
    rcorr = r - (r - 1)**2 / (n - 1)
    kcorr = k - (k - 1)**2 / (n - 1)

    return np.sqrt(phi2corr / min((kcorr - 1), (rcorr - 1)))


cols_v = cols_bin + cols_ordinal + cols_semiar + [target]

mat = pd.DataFrame(index=cols_v, columns=cols_v)

for c1 in cols_v:
    for c2 in cols_v:
        tab = pd.crosstab(df[c1], df[c2])
```

```
mat.loc[c1, c2] = cramers_v_corrected(tab.values)

plt.figure(figsize=(20,8))
sns.heatmap(mat.astype(float), annot=True, cmap='Blues', vmin=0, vmax=1)
plt.title("Categorical Association (Cramér's V Corrected)")
plt.show()
```



Pré-processamento

- O estágio de pré-processamento foi conduzido para garantir que o modelo fosse treinado com dados íntegros, evitando vieses e garantindo a aplicabilidade clínica em cenários de triagem real. - Identificação e Mitigação de Vazamento de Dados (Data Leakage): O ponto mais crítico desta etapa foi a análise de vazamento de dados. Identificamos que as variáveis MentHlth (dias de saúde mental ruim) e PhysHlth (dias de saúde física ruim) representavam potenciais problemas para a generalização do modelo: . Justificativa da Exclusão: Estas variáveis contêm consequências diretas e crônicas do diabetes já estabelecido, funcionando como "marcadores do futuro" dentro do histórico do paciente; . Ação: Para evitar que o modelo fizesse previsões baseadas em sintomas tardios da doença (o que inflaria artificialmente as métricas de performance), as variáveis MentHlth e PhysHlth foram formalmente excluídas do conjunto de treinamento. - Transformação e Codificação de Variáveis: Para otimizar o processamento pelos algoritmos de gradiente (XGBoost e LGBM), os dados foram organizados através de um ColumnTransformer: . Variáveis Numéricas: O IMC (BMI) passou por um processo de StandardScaler, centralizando a média em zero e escalonando a variância para unidade, facilitando a convergência do modelo; . Variáveis Categóricas e Ordinais: As variáveis Age e Income foram tratadas via One-Hot Encoding (OHE), permitindo que o modelo capturasse relações não-lineares em cada faixa etária ou de renda, sem assumir uma progressão aritmética simples entre as categorias; . Variáveis Binárias: Treze atributos (como HighBP, Smoker e Stroke) foram mantidos em formato binário (0 ou 1), preservando a natureza direta dessas informações conforme o dicionário do CDC.

- Dataset para pré-processamento

```
In [30]: df_prep = df_eda.copy()
```

- Features irrelevantes

```
In [31]: # Features relacionadas a Leakage
irrelevant_features=["MentHlth", "PhysHlth"]
```

```
df_prep = df_prep.drop(columns=irrelevant_features).reset_index(drop=True)
```

- Pré-processador

```
In [32]: cols_bin = ["HighBP", "HighChol", "CholCheck", "Smoker", "Stroke", "HeartDiseaseorA",  
                  "Fruits", "Veggies", "HvyAlcoholConsump", "AnyHealthcare", "NoDocbcCost",  
                  "Diabetes_binary"]  
  
cols_ordinal = ["GenHlth", "Education"]  
  
cols_semiar = ["Age", "Income"]  
  
cols_numeric = ["BMI"]  
  
target = "Diabetes_binary"
```

```
In [33]: preprocessor = ColumnTransformer(  
    transformers=[  
        ("bin", "passthrough", cols_bin),           # binárias → ok  
        ("ord", "passthrough", cols_ordinal),       # ordinais → ok  
        ("ohe", OneHotEncoder(drop="first"), cols_semiar), # AGE & INCOME → OHE  
        ("num", StandardScaler(), cols_numeric),    # BMI → scaling  
    ],  
    remainder="drop"  
)
```

- Separar X e Y

```
In [34]: X = df_prep.drop(columns = ['Diabetes_binary'])  
y = df_prep['Diabetes_binary']
```


- Dividir em treino/teste

```
In [35]: X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

- Seleção de Features

```
In [37]: pipeline = Pipeline(steps=[  
    ("preprocess", preprocessor),           # já tem scaler  
    ("feature_selection", SelectKBest(score_func=mutual_info_classif, k="all")), #  
    ("model", LogisticRegression(max_iter=1000))  
)  
  
pipeline.fit(X_train, y_train)
```

Out[37]:



Treinamento e Avaliação de Modelos Base

- Os modelos selecionados foram o LGBM e o XGBoost.

- Criar um Avaliador Universal

```
In [39]: def evaluate_model(name, pipeline, X_test, y_test):
    """
    Avaliador para o Dataset CDC Diabetes (Sem reamostragem).
    Focado em métricas de separação probabilística.
    """
    print(f"\n{'='*40}\nMODEL: {name}\n{'='*40}")

    # 1. Predição de Probabilidades (Sempre o primeiro passo para avaliação técnica)
    # O pipeline já cuida do transform(X_test) internamente
    y_proba = pipeline.predict_proba(X_test)[:, 1]

    # 2. Predição de Classe (Threshold padrão 0.5)
    y_pred = pipeline.predict(X_test)

    # 3. Métricas de Performance (Cruciais para desbalanceamento moderado)
    roc_auc = roc_auc_score(y_test, y_proba)
    ap = average_precision_score(y_test, y_proba)

    print(f"ROC-AUC SCORE: {roc_auc:.4f}")
    print(f"AVERAGE PRECISION (AP): {ap:.4f}")
    print("\nCLASSIFICATION REPORT (Threshold 0.50):")
    print(classification_report(y_test, y_pred))

    # 4. Matriz de Confusão Visual para o relatório
    fig, ax = plt.subplots(figsize=(5, 4))
    ConfusionMatrixDisplay.from_predictions(y_test, y_pred, ax=ax, cmap='Blues', va='top')
    plt.title(f"Confusion Matrix: {name}")
    plt.show()

    return {"name": name, "roc_auc": roc_auc, "ap": ap, "y_proba": y_proba}
```

- Pipeline para cada modelo

```
In [41]: # 1. Instanciar e ajustar o LabelEncoder no alvo (target)
le = LabelEncoder()

# 2. Transformar y_train e y_test (Garante que Diabetes=1 e Saudável=0)
y_train_num = le.fit_transform(y_train)
y_test_num = le.transform(y_test)

# 3. Recalcular os pesos para o XGBoost usando o y_train numérico
pesos_treino = compute_sample_weight(class_weight='balanced', y=y_train_num)

# 4. Conferir o mapeamento
print(f"Map: {dict(zip(le.classes_, range(len(le.classes_))))}")
```

Map: {np.int64(0): 0, np.int64(1): 1}

```
In [44]: # 1. Dummy
dummy_pipe = Pipeline(steps=[
    ("preprocess", preprocessor),
    ("model", DummyClassifier(strategy="most_frequent", random_state=42))
])

dummy_pipe.fit(X_train, y_train_num)
evaluate_model("Baseline (Naive)", dummy_pipe, X_test, y_test_num)

# 2. Logistic Regression
logreg_pipe = Pipeline(steps=[
    ("preprocess", preprocessor),
    ("model", LogisticRegression(
        max_iter=2000,
        class_weight="balanced",
        random_state=42
    ))
])

logreg_pipe.fit(X_train, y_train_num)
evaluate_model("Regressão Logística", logreg_pipe, X_test, y_test_num)

# 3. Random Forest
rf_pipe = Pipeline(steps=[
    ("preprocess", preprocessor),
    ("model", RandomForestClassifier(
        random_state=42,
        class_weight="balanced"
    ))
])

rf_pipe.fit(X_train, y_train_num)
evaluate_model("Random Forest", rf_pipe, X_test, y_test_num)

# 4. XGBoost
xgb_pipe = Pipeline(steps=[
    ("preprocess", preprocessor),
    ("model", XGBClassifier(
```



```

        objective='binary:logistic',
        random_state=42,
        verbosity=0
    ))
])

xgb_pipe.fit(X_train, y_train_num, model__sample_weight=pesos_treino)
evaluate_model("XGBoost", xgb_pipe, X_test, y_test_num)

# 5. LGBM
lgbm_pipe = Pipeline(steps=[
    ("preprocess", preprocessor),
    ("model", LGBMClassifier(
        random_state=42,
        class_weight="balanced",
    ))
])

lgbm_pipe.fit(X_train, y_train_num)
evaluate_model("LGBM", lgbm_pipe, X_test, y_test_num)

```

```

=====
MODEL: Baseline (Naive)
=====
ROC-AUC SCORE: 0.5000
AVERAGE PRECISION (AP): 0.1529


```

```

CLASSIFICATION REPORT (Threshold 0.50):

```

	precision	recall	f1-score	support
0	0.85	1.00	0.92	38876
1	0.00	0.00	0.00	7019
accuracy			0.85	45895
macro avg	0.42	0.50	0.46	45895
weighted avg	0.72	0.85	0.78	45895



=====

MODEL: Regressão Logística


=====

ROC-AUC SCORE: 0.8124

AVERAGE PRECISION (AP): 0.4206

CLASSIFICATION REPORT (Threshold 0.50):

	precision	recall	f1-score	support
0	0.94	0.71	0.81	38876
1	0.32	0.76	0.45	7019
accuracy			0.72	45895
macro avg	0.63	0.74	0.63	45895
weighted avg	0.85	0.72	0.75	45895



=====

MODEL: Random Forest


=====

ROC-AUC SCORE: 0.7603

AVERAGE PRECISION (AP): 0.3283

CLASSIFICATION REPORT (Threshold 0.50):

	precision	recall	f1-score	support
0	0.87	0.95	0.91	38876
1	0.40	0.18	0.25	7019
accuracy			0.83	45895
macro avg	0.63	0.57	0.58	45895
weighted avg	0.79	0.83	0.81	45895



=====

MODEL: XGBoost


=====

ROC-AUC SCORE: 0.8108

AVERAGE PRECISION (AP): 0.4300

CLASSIFICATION REPORT (Threshold 0.50):

	precision	recall	f1-score	support
0	0.94	0.70	0.80	38876
1	0.32	0.77	0.45	7019
accuracy			0.71	45895
macro avg	0.63	0.74	0.63	45895
weighted avg	0.85	0.71	0.75	45895




```
[LightGBM] [Info] Number of positive: 28078, number of negative: 155501
[LightGBM] [Info] Auto-choosing row-wise multi-threading, the overhead of testing was 0.009174 seconds.
You can set `force_row_wise=true` to remove the overhead.
And if memory is not enough, you can set `force_col_wise=true`.
[LightGBM] [Info] Total Bins 155
[LightGBM] [Info] Number of data points in the train set: 183579, number of used features: 36
[LightGBM] [Info] [binary:BoostFromScore]: pavg=0.500000 -> initscore=0.000000
[LightGBM] [Info] Start training from score 0.000000
```

```
=====
MODEL: LGBM
=====
```

```
ROC-AUC SCORE: 0.8168
AVERAGE PRECISION (AP): 0.4422
```

```
CLASSIFICATION REPORT (Threshold 0.50):
```

	precision	recall	f1-score	support
0	0.95	0.69	0.80	38876
1	0.32	0.79	0.45	7019
accuracy			0.71	45895
macro avg	0.63	0.74	0.63	45895
weighted avg	0.85	0.71	0.75	45895



```
Out[44]: {'name': 'LGBM',
          'roc_auc': 0.8168069830919592,
          'ap': 0.4421786735789712,
          'y_proba': array([0.67360225, 0.0341592 , 0.36384847, ..., 0.45200326, 0.0929382
7,
          0.41067707], shape=(45895,))}
```

```
In [45]: def get_metrics(model, X_test, y_test):
          # Predição das classes
          y_pred = model.predict(X_test)

          # Predição das probabilidades
          if hasattr(model, "predict_proba"):
              y_proba = model.predict_proba(X_test)[: , 1]
          else:
              y_proba = None

          # --- MÉTRICAS PRIORITÁRIAS ---
          # AP: Melhor para dados desbalanceados (mede a área sob a curva Precision-Recall)
          ap = average_precision_score(y_test, y_proba) if y_proba is not None else 0

          # AUC: Mede a capacidade de separação global
          auc = roc_auc_score(y_test, y_proba) if y_proba is not None else 0

          # RECALL (Classe 1): Quão bom o modelo é em achar os diabéticos?
          # Em saúde, o falso negativo é mais perigoso que o falso positivo.
          recall_pos = recall_score(y_test, y_pred)

          # F1-Score da Classe 1: O equilíbrio para a classe que nos interessa
          f1_pos = f1_score(y_test, y_pred)

          return ap, auc, recall_pos, f1_pos
```

```
In [46]: results = []

# Dicionário com todos os pipelines que você treinou
models = {
    "Baseline (Naive)": dummy_pipe,
    "Logistic Regression": logreg_pipe,
    "Random Forest": rf_pipe,
    "XGBoost": xgb_pipe,
    "LGBM": lgbm_pipe
}

for name, model in models.items():
    ap, auc, recall, f1 = get_metrics(model, X_test, y_test_num)
    results.append([name, ap, auc, recall, f1])

# Criando o DataFrame de Resultados
df_results = pd.DataFrame(results, columns=["Model", "Avg Precision", "ROC-AUC", "R

# Ordenando pela Average Precision
df_results.sort_values("Avg Precision", ascending=False, inplace=True)
df_results
```

```
Out[46]:
```

	Model	Avg Precision	ROC-AUC	Recall (Pos)	F1-Score (Pos)
4	LGBM	0.442179	0.816807	0.792563	0.451707
3	XGBoost	0.429954	0.810840	0.770765	0.449168
1	Logistic Regression	0.420553	0.812359	0.764639	0.451046
2	Random Forest	0.328258	0.760262	0.183075	0.250634
0	Baseline (Naive)	0.152936	0.500000	0.000000	0.000000

Modelos Promissores

- LGBM é o modelo escolhido. Apesar do XGBoost ter uma métrica de precisão média melhor (levemente), o recall da classe positiva do LGBM é bastante superior.

```
In [47]: # Criar um diretório temporário para cache
cachedir = mkdtemp()
```

- LGBM

```
In [48]: # Pipeline com Cache
lgbm_pipe_grid = Pipeline(steps=[
    ("preprocess", preprocessor),
    ("model", LGBMClassifier(random_state=42))
], memory=cachedir)

# Grid para LGBM: Foco em folhas e regularização
param_grid_lgbm = {
    'model__n_estimators': [200, 500],
```

```

    'model_num_leaves': [63, 127],          # Dobramos a complexidade das folh
    'model_max_depth': [-1, 10],           # -1 significa sem limite (control
    'model_learning_rate': [0.01, 0.05],
    'model_min_child_samples': [20, 50],    # Evita folhas com poucos dados
    'model_class_weight': ['balanced', None] # Testamos se o peso automático é
}

grid_lgbm = RandomizedSearchCV(
    lgbm_pipe_grid,
    param_grid_lgbm,
    cv=3,
    scoring='average_precision',
    n_jobs=-1
)

print("Starting Search LGBM...")
grid_lgbm.fit(X_train, y_train_num)

```

Starting Search LGBM...

[LightGBM] [Info] Number of positive: 28078, number of negative: 155501

[LightGBM] [Info] Auto-choosing row-wise multi-threading, the overhead of testing was 0.010421 seconds.

You can set `force\_row\_wise=true` to remove the overhead.

And if memory is not enough, you can set `force\_col\_wise=true`.


[LightGBM] [Info] Total Bins 155

[LightGBM] [Info] Number of data points in the train set: 183579, number of used features: 36

[LightGBM] [Info] [binary:BoostFromScore]: pavg=0.500000 -> initscore=0.000000

[LightGBM] [Info] Start training from score 0.000000

Out[48]:



- XGBoost

In [49]:

```

# Pipeline com Cache
xgb_pipe_grid = Pipeline(steps=[
    ("preprocess", preprocessor),
    ("model", XGBClassifier(objective='binary:logistic', random_state=42, verbosity
)], memory=cachedir)

# Grid para XGBoost: Foco em profundidade e regularização
param_grid_xgb = {

```



```

'model__n_estimators': [200, 500],          # Aumentamos para dar mais fôlego
'model__max_depth': [6, 8],                 # Árvores mais profundas para capt
'model__learning_rate': [0.01, 0.05],       # Menor learning rate exige mais á
'model__subsample': [0.8],                  # Evita overfitting treinando com
'model__colsample_bytree': [0.8],           # Treina com 80% das colunas por á
'model__scale_pos_weight': [3, 5, 7]       # Testamos níveis diferentes de ag
}


grid_xgb = RandomizedSearchCV(
    xgb_pipe_grid,
    param_grid_xgb,
    cv=3,
    scoring='average_precision', # Foco em dados desbalanceados
    n_jobs=-1
)

print("Starting Search XGBoost...")
grid_xgb.fit(X_train, y_train_num)

```

Starting Search XGBoost...

Out[49]:



- Comparação dos modelos promissores

```

In [50]: # Dicionário atualizado com os melhores modelos do GridSearch
models_optimized = {
    "XGBoost (Tuned)": grid_xgb.best_estimator_,
    "LGBM (Tuned)": grid_lgbm.best_estimator_
}

results_opt = []

# Usando a função get_metrics adaptada para saúde que criamos antes
for name, model in models_optimized.items():
    ap, auc, recall, f1 = get_metrics(model, X_test, y_test_num)
    results_opt.append([name, ap, auc, recall, f1])

# DataFrame com as métricas prioritárias
df_results_opt = pd.DataFrame(
    results_opt,

```

```

columns=["Modelo", "Avg Precision (AP)", "ROC-AUC", "Recall (Pos)", "F1-Score (
)

# Ordenação pelo "padrão ouro" de dados desbalanceados (Average Precision)
df_results_opt.sort_values("Avg Precision (AP)", ascending=False, inplace=True)
df_results_opt

```

Out[50]:

	Modelo	Avg Precision (AP)	ROC-AUC	Recall (Pos)	F1-Score (Pos)
0	XGBoost (Tuned)	0.443889	0.816743	0.580994	0.473251
1	LGBM (Tuned)	0.442491	0.816330	0.780026	0.452143

Análise de Erros e Interpretação do Modelo Final

- A avaliação final do modelo revelou uma performance robusta para o cenário de triagem clínica. O algoritmo escolhido, LGBM (Tuned), apresentou uma capacidade de separação global (ROC-AUC) de 0.8163, demonstrando um aprendizado sólido dos padrões epidemiológicos do CDC. - Estratégia de Decisão e Gestão de Risco: Considerando que o objetivo principal de uma política de triagem é a detecção precoce para reduzir complicações crônicas, adotamos um Threshold Clínico de 0.25. Esta decisão estratégica priorizou a sensibilidade em detrimento da precisão: . Recall (Sensibilidade): Atingimos 94.56%, o que permitiu identificar 6637 casos reais de diabetes; . Minimização de Erros Críticos: Apenas 382 falsos negativos ocorreram, garantindo que a vasta maioria dos doentes receba encaminhamento médico; . Eficiência de Custos: Embora o modelo gere alarmes falsos, o custo de exames laboratoriais confirmatórios para esses indivíduos é marginal comparado ao custo social e econômico de tratar complicações de um diabetes não diagnosticado. - Calibração e Confiabilidade: O modelo apresentou um Brier Score de 0.1807. Embora a curva de calibração indique uma tendência conservadora na estimativa das probabilidades, a separação das classes no gráfico de densidade confirma que o sistema é capaz de distinguir com clareza a massa de indivíduos saudáveis dos diabéticos. - Interpretabilidade Global e Local (SHAP): Através da análise SHAP, validamos que as decisões do modelo estão alinhadas com a literatura médica. As variáveis de maior impacto foram a Saúde Geral Percebida (GenHlth), a Pressão Arterial (HighBP) e o IMC (BMI): . Fatores de Risco: Um IMC acima de 27 demonstrou ser o ponto de virada onde o risco sobe exponencialmente; . Casos Individuais: O uso de Force Plots permitiu personificar o risco. Enquanto um paciente de alto risco (93%) apresenta convergência de múltiplos fatores como BMI = 39 e hipertensão, um perfil saudável apresenta probabilidade de apenas 1% devido à ausência de comorbidades e peso adequado.

- Análise de Thresholds Clínicos (Ponto de Corte)

- Foi utilizado um threshold de 0.25 para priorizar a detecção precoce (Recall alto). Embora isso gere mais alarmes falsos (Precisão de 23%), o custo de um teste de sangue confirmatório é negligenciável comparado ao tratamento de complicações crônicas por diabetes não diagnosticada.

```

In [51]: # 1. Obter probabilidades para a classe positiva (Diabetes - índice 1)
y_proba = grid_lgbm.best_estimator_.predict_proba(X_test)[: , 1]

# 2. Calcular precision e recall
precision, recall, thresholds = precision_recall_curve(y_test_num, y_proba)

plt.figure(figsize=(12, 5))

# Plotar as curvas
plt.plot(thresholds, precision[: -1], 'b--', label='Precision (Avoid False Positives)')
plt.plot(thresholds, recall[: -1], 'r-', label='Recall (Capture diabetics cases)', 1

# Encontrar o ponto de equilíbrio (onde se cruzam)
# (Opcional: apenas para referência visual)
idx = np.argmax(np.diff(np.sign(precision - recall))).flatten()

```


```

if len(idx) > 0:
    plt.axvline(thresholds[idx[0]], color='gray', linestyle='--', alpha=0.5)
    plt.text(thresholds[idx[0]], 0.1, f' Equilibrium: {thresholds[idx[0]]:.2f}', fo

# 2. Marcar o Threshold de Negócio Sugerido
# Para o CDC, um valor entre 0.2 e 0.3 costuma ser excelente para Recall alto
threshold_clinico = 0.25
plt.axvline(threshold_clinico, color='black', linestyle=':', label=f'Suggested Clin

plt.title('Precision-Recall Curve vs. Threshold')
plt.xlabel('Probability Threshold')
plt.ylabel('Score (0 - 1)')
plt.legend(loc='best')
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()

```



- Probabilidades preditas e calibração

- A estratégia de adotar o Threshold de 0.25 é a mais correta para um gestor de saúde, pois: . Redução de Risco: Maximiza a detecção precoce (Recall), que é o objetivo principal de uma política de triagem do CDC; . Eficiência de Custos: O custo de exames confirmatórios para os "falsos positivos" (área azul à direita da linha vermelha) é compensado pela prevenção de complicações agudas e crônicas do diabetes não tratado; . Maturidade do Modelo: O fato de as duas massas estarem bem separadas no gráfico de densidade prova que o LGBM realmente aprendeu os fatores de risco e não está apenas "chutando" com base na prevalência.

```

In [53]: plt.figure(figsize=(12, 5))

# 1. Distribuição para quem REALMENTE não tem diabetes (Classe 0)
sns.kdeplot(
    y_proba[y_test_num == 0],
    fill=True,
    color="steelblue",
    label="Real: Healthy (Class 0)",
    bw_adjust=0.7
)

# 2. Distribuição para quem REALMENTE tem diabetes (Classe 1)
sns.kdeplot(
    y_proba[y_test_num == 1],
    fill=True,

```


```

        color="seagreen",
        label="Real: Diabetes (Class 1)",
        bw_adjust=0.7
    )

# 3. Linhas de Threshold para Comparação
plt.axvline(0.5, color="gray", linestyle="--", label="Standard Threshold (0.5)")
plt.axvline(0.25, color="red", linestyle="-", linewidth=2, label="Clinical Threshold")

# 4. Formatação
plt.title("Class Separation and Clinical Decision Threshold")
plt.xlabel("Predicted Probability of Diabetes")
plt.ylabel("Patient Density")
plt.xlim(0, 1)
plt.legend(loc='best')
plt.grid(alpha=0.2)
plt.tight_layout()
plt.show()

```



- Calibração

- A curva do modelo está consistentemente abaixo da linha de "Calibração Perfeita". Isso indica que o modelo tende a ser conservador: quando ele prevê 60% de chance, a frequência real observada é de cerca de 20%.

```

In [54]: # 1. Calcular a Curva de Calibração
# n_bins=10 divide as probabilidades em fatias de 10%
prob_true, prob_pred = calibration_curve(y_test_num, y_proba, n_bins=10)

# 2. Calcular Brier Score (Quanto menor, melhor a calibração)
brier = brier_score_loss(y_test_num, y_proba)
print(f"Brier Score (Diabetes): {brier:.4f}")


# 3. Plotagem
plt.figure(figsize=(12, 5))
plt.plot(prob_pred, prob_true, marker='s', linewidth=2, label=f'Model Optimized (Brier Score: {brier:.4f})')
plt.plot([0, 1], [0, 1], linestyle='--', color='black', alpha=0.6, label='Perfect Calibration')

plt.xlabel('Probability Predicted by the Model')
plt.ylabel('Observed Frequency (Reality)')
plt.title('Calibration Curve: Reliability of Diabetes Predictions')

```

```
plt.legend(loc='best')
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()
```

Brier Score (Diabetes): 0.1807



- Curva ROC-AUC


- Capacidade de Separação: A curva está bem afastada da linha de base (Random Classifier), demonstrando que o modelo aprendeu padrões relevantes nos dados e oferece um desempenho superior ao acaso.

```
In [55]: # Curva ROC
fpr, tpr, thresholds = roc_curve(y_test, y_proba)

# AUC
auc = roc_auc_score(y_test, y_proba)

plt.figure(figsize=(12, 5))
plt.plot(fpr, tpr, lw=2, label=f"AUC = {auc:.4f}")
plt.plot([0, 1], [0, 1], "--", color="gray", label="Random Classifier")

plt.xlabel("False Positive Rate")
plt.ylabel("True Positive Rate")
plt.title("ROC Curve – Class 1 (Diabetes)")
plt.legend(loc="lower right")
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()
```



- Matriz de confusão

- Com o threshold de 0.25, o modelo atingiu uma Sensibilidade (Recall) de 94.56%, identificando 6637 casos de diabetes e perdendo apenas 382 (Falsos Negativos).


```
In [56]: # 1. Aplicar o Threshold Clínico de 0.25 (definido nas análises anteriores)
# Isso transforma probabilidades em classes (0 ou 1)
y_pred_clinico = (y_proba >= 0.25).astype(int)

# 2. Gerar a Matriz de Confusão
cm = confusion_matrix(y_test_num, y_pred_clinico)

# 3. Plotagem
plt.figure(figsize=(8, 6))
sns.heatmap(cm, annot=True, fmt="d", cmap="Blues",
            xticklabels=['Healthy (0)', 'Diabetes (1)'],
            yticklabels=['Healthy (0)', 'Diabetes (1)'])

plt.xlabel("Model Prediction (Threshold 0.25)")
plt.ylabel("Reality (CDC Data)")
plt.title("Confusion Matrix: Screening Strategy")
plt.tight_layout()
plt.show()

# 4. Extração de Métricas de Negócio
tn, fp, fn, tp = cm.ravel()
recall = tp / (tp + fn)
print(f"Sensitivity (Recall): {recall:.2%}")
print(f"Diabetes cases identified: {tp}")
print(f"Missed Diabetes Cases (False Negatives): {fn}")
```



Sensitivity (Recall): 94.56%
 Diabetes cases identified: 6637
 Missed Diabetes Cases (False Negatives): 382

- Shap summary

- GenHlth (Saúde Geral): É a variável de maior impacto. Valores altos (indicando percepção de saúde ruim) estão fortemente associados a um aumento drástico no risco de diabetes. - HighBP (Pressão Alta): O modelo identifica a hipertensão como um fator crítico. Ter pressão alta (cor vermelha) empurra a predição significativamente para a direita, aumentando a probabilidade da doença. - BMI (IMC): Como esperado na literatura médica, um IMC elevado correlaciona-se com maior risco. Note que há uma distribuição contínua de pontos vermelhos se espalhando para a direita, sugerindo que quanto maior o IMC, maior o impacto positivo no risco.

```
In [57]: # =====
# 1. PREPARAÇÃO DO DATAFRAME COM NOMES LIMPOS
# =====

# Recuperar o pré-processador e o modelo do pipeline
# (Ajuste 'grid_xgb' para o nome da variável do GridSearchCV)
preprocessor_step = grid_lgbm.best_estimator_.named_steps['preprocess']
classifier_model = grid_lgbm.best_estimator_.named_steps['model']

# Transformar o X_test e recuperar os nomes originais das colunas
X_test_transformed = preprocessor_step.transform(X_test)
feature_names_raw = preprocessor_step.get_feature_names_out()

# Criar o DataFrame para o SHAP
df_shap = pd.DataFrame(X_test_transformed, columns=feature_names_raw)
```

```

# --- LIMPEZA DOS NOMES (Removendo prefixos bin__, ord__, num__, ohe__) ---
# O regex r'^.*__' remove tudo desde o início até o duplo underscore
df_shap.columns = df_shap.columns.str.replace(r'^.*__', '', regex=True)

# =====
# 2. CÁLCULO DO SHAP VALUES
# =====

# Criar o explicador otimizado para árvores (XGBoost/LGBM)
explainer = shap.TreeExplainer(classifier_model)

# Calcular os valores SHAP
# check_additivity=False evita erros comuns com modelos complexos em bases grandes
shap_values = explainer.shap_values(df_shap, check_additivity=False)

# Garantir que estamos pegando os valores da classe 1 (Diabetes)
# Dependendo da versão do SHAP/XGBoost, o retorno pode variar de formato
if isinstance(shap_values, list):
    shap_values_target = shap_values[1]
elif len(shap_values.shape) == 3:
    shap_values_target = shap_values[:, :, 1]
else:
    shap_values_target = shap_values

# =====
# 3. PLOTAGEM DO SUMMARY PLOT
# =====


plt.figure(figsize=(12, 10))
plt.title("Impact of Variables on Diabetes Risk (SHAP Values)", fontsize=16, pad=20)

# O summary_plot usa o DataFrame df_shap com as colunas já limpas
shap.summary_plot(
    shap_values_target,
    df_shap,
    show=False,
    plot_type="dot" # ou "bar" se preferir apenas a importância global
)

plt.xlabel("SHAP Impact (Risk Direction)", fontsize=12)
plt.tight_layout()
plt.show()

```


Impact of Variables on Diabetes Risk (SHAP Values)



- Shap dependence plot

- Pacientes que avaliam sua própria saúde como 4 ou 5 têm um salto drástico no impacto SHAP (de negativo para positivo acima de 1.0). Isso valida a autopercepção do paciente como um indicador clínico confiável para triagem inicial. - Indivíduos sem pressão alta (0) têm impacto SHAP negativo (fator de proteção). Ao mudar para o grupo com pressão alta (1), o impacto salta imediatamente para valores positivos entre 0.4 e 0.8. - O "Ponto de Virada": O risco (Impacto SHAP) cruza a linha zero exatamente em torno do IMC 25-27. . Abaixo de 25: O IMC atua como fator de proteção; . Acima de 27: O risco sobe exponencialmente até o IMC 40.

```
In [59]: # =====
# 1. PREPARAÇÃO DO DATASET DE EXIBIÇÃO (VALORES REAIS)
```

```

# =====

# Usamos o DataFrame transformado que contém os nomes das colunas (OHE + Numeric)
X_display = pd.DataFrame(X_test_transformed, columns=feature_names_raw).copy()

# Limpeza visual dos nomes das colunas
X_display.columns = [col.split('__')[-1] for col in X_display.columns]

# Sincronizamos com X_test para restaurar a escala real das variáveis numéricas
# No CDC Diabetes, a principal variável numérica é o 'BMI'
cols_para_restaurar = ['BMI']

for col in cols_para_restaurar:
    if col in X_display.columns:
        # Substituímos o valor escalonado pelo valor original do X_test
        X_display[col] = X_test[col].values
        print(f"Restored to real scale for: {col}")

# =====
# 2. IDENTIFICAR AS TOP FEATURES DO MODELO
# =====

# Calculamos a importância média absoluta baseada no SHAP (Classe 1 - Diabetes)
vals = np.abs(shap_values_target).mean(0)

feature_importance = pd.DataFrame(
    list(zip(X_display.columns, vals)),
    columns=['col_name', 'importance']
)

feature_importance.sort_values(by='importance', ascending=False, inplace=True)
top_features_names = feature_importance['col_name'].head(3).tolist()

print(f"Top 3 Features for dependency analysis: {top_features_names}")

# =====
# 3. PLOTAGEM DOS DEPENDENCE PLOTS
# =====

n_features = len(top_features_names)
fig, axes = plt.subplots(nrows=1, ncols=n_features, figsize=(7*n_features, 5))

if n_features == 1: axes = [axes]

for i, feature_name in enumerate(top_features_names):
    # O dependence_plot mostra a relação entre o valor da feature e o impacto no mo
    shap.dependence_plot(
        feature_name,
        shap_values_target, # Matriz SHAP da Classe 1 calculada anteriormente
        X_display,          # DataFrame com nomes limpos e escala real
        interaction_index="auto", # SHAP define automaticamente a cor baseada em ou
        ax=axes[i],
        show=False,
        alpha=0.6,
        dot_size=20
    )

```

```


axes[i].set_title(f"Dependence: {feature_name}", fontsize=13, fontweight='bold')
axes[i].set_ylabel("SHAP Impact (Diabetes Risk)")
axes[i].grid(True, linestyle='--', alpha=0.4)

plt.tight_layout()
plt.show()

```

Restored to real scale for: BMI

Top 3 Features for dependency analysis: ['GenHlth', 'HighBP', 'BMI']



- Shap force plot

- Perfil de Risco Máximo (Paciente 30317): Este gráfico mostra como as variáveis se somam para elevar a probabilidade de diabetes a 93%: . Fatores de Impulso (Vermelho): O grande "vilão" aqui é o BMI = 39, que empurra drasticamente a predição para a direita. Ele é acompanhado por uma percepção de saúde péssima (GenHlth = 5), hipertensão (HighBP = 1) e colesterol alto (HighChol = 1); . Comorbidades: O fato de o paciente já ter tido um ataque cardíaco e ter dificuldade de locomoção (DiffWalk = 1) adiciona camadas finais de risco que o modelo captura com precisão; . Interpretação: É um caso clássico onde múltiplos fatores de risco metabólicos e históricos clínicos convergem. - Perfil de Risco Mínimo (Paciente 5421): Em oposição, este paciente tem uma probabilidade de apenas 1%: . Fatores de Proteção (Azul): A ausência de doenças crônicas (HighBP = 0, HighChol = 0) e um peso saudável (BMI = 17) são os principais responsáveis por "puxar" a predição para a esquerda, neutralizando o valor base do modelo; . Estilo de Vida e Juventude: A excelente percepção de saúde (GenHlth = 1) consolidam o perfil de baixo risco.

```

In [60]: # =====
# 1. PREPARAÇÃO DO DATAFRAME DE EXIBIÇÃO (VALORES REAIS)
# =====
# A. Limpeza definitiva dos nomes (remove bin_, ohe_, num_, etc.)
X_display.columns = [col.split('__')[-1] for col in X_display.columns]

# B. Restauração da escala real (essencial para o BMI e Age)
# Sincronizamos com o X_test original para que o gráfico mostre "BMI: 32" e não "BM
cols_reais = ['BMI'] # Adicione outras se não forem 0/1 (ex: Age, se não for OHE)
X_raw_full = X_test.copy()

for col in cols_reais:
    if col in X_display.columns:
        X_display[col] = X_raw_full[col].values

# =====
# 2. AJUSTE DE VALORES SHAP E IDENTIFICAÇÃO DE CASOS EXTREMOS
# =====

# A. Valor Base (Expected Value)
base_value = explainer.expected_value
if isinstance(base_value, (list, np.ndarray)) and len(base_value) > 1:
    base_value = base_value[1]

# B. Cálculo das predições em log-odds para encontrar os extremos

```

```

# shap_values_target foi definido no bloco do Summary Plot (Classe 1)
total_predictions = shap_values_target.sum(axis=1) + base_value

idx_high = np.argmax(total_predictions) # Paciente com maior risco de diabetes
idx_low = np.argmin(total_predictions) # Paciente com menor risco de diabetes

print(f"High-Risk Patient (Index {idx_high}): Log-odds {total_predictions[idx_high]}")
print(f"Low-Risk Patient (Index {idx_low}): Log-odds {total_predictions[idx_low]:.2}")

# =====
# 3. GERAR FORCE PLOTS (INDIVIDUAL EXPLANATION)
# =====

def plot_force_diabetes(idx_pos, title):
    print(f"\n{'='*50}\n{title}\n{'='*50}")

    # Inicializa JS (necessário para force_plot interativo no Jupyter)
    shap.initjs()

    # Link='logit' converte a escala de Log-odds para Probabilidade (0 a 100%)
    # Isso permite que a banca veja: "Probabilidade Final: 85%"
    return shap.force_plot(
        base_value,
        shap_values_target[idx_pos],
        X_display.iloc[idx_pos, :],
        link="logit",
        matplotlib=False # Define como False para manter a interatividade
    )

# Exibir os perfis individuais
display(plot_force_diabetes(idx_high, "Clinical Profile: Maximum Risk of Diabetes"))
display(plot_force_diabetes(idx_low, "Clinical Profile: Minimal Risk of Diabetes"))

```

High-Risk Patient (Index 30317): Log-odds 2.66

Low-Risk Patient (Index 5421): Log-odds -5.09

```

=====
Clinical Profile: Maximum Risk of Diabetes
=====

```



0.003341 0.00903 0.02417 0.06309 0.1547 base val 0.332


Age_9 = 1 | DiffWalk = 1 | Stroke = 1 | HeartDiseaseorAttack

```

=====
Clinical Profile: Minimal Risk of Diabetes
=====

```





Salvando o Modelo

```
In [61]: # 1. Preparar o objeto consolidado
# É uma boa prática salvar o pipeline e as classes juntos
export_data = {
    "pipeline": grid_lgbm.best_estimator_, # Garanta que está salvando o melhor mod
    "classes": le.classes_.tolist(),
    "threshold": 0.25 # Recomendável salvar o threshold clínico escolhido
}

# 2. Salvar com compressão máxima (3 a 9 são níveis comuns)
# Isso reduz o tamanho do arquivo, facilitando o upload/download
joblib.dump(export_data, "modelo_diabetes_vt1.pkl", compress=3)
```

```
Out[61]: ['modelo_diabetes_vt1.pkl']
```

Síntese

- O objetivo central: . A meta deste trabalho foi desenvolver um sistema de apoio à decisão clínica capaz de realizar a triagem populacional de diabetes mellitus utilizando indicadores de saúde do CDC. Buscou-se ir além da predição binária, focando na criação de um modelo que priorizasse segurança do paciente através de uma alta sensibilidade (Recall) e que fosse totalmente interpretável para profissionais de saúde. - Metodologia Resumida: . A metodologia baseou-se no processamento de 253680 registros, passando por uma rigorosa etapa de limpeza e exclusão de variáveis com risco de data leakage. Foram testados diversos algoritmos, incluindo Random Forest e Regressão Logística, mas os modelos de gradient boosting (XGBoost e LGBM) destacaram-se após a otimização de hiperparâmetros via RandomizedSearchCV. A arquitetura final foi consolidada em um Pipeline de produção integrado a uma aplicação Streamlit. - Resultados: . O modelo vencedor (LGBM Tuned) alcançou uma métrica de separação ROC-AUC de 0.8163. Ao adotar um threshold estratégico de 0.25, o sistema atingiu uma sensibilidade (Recall) de 94.56%, identificando corretamente 6637 casos de diabetes no conjunto de teste. As análises via SHAP confirmaram que o IMC, a pressão alta e a autopercepção de saúde são os principais vetores de risco, validando o modelo sob a ótica da literatura médica. - Limitações: . Apesar da alta performance, o modelo apresenta uma precisão de 23% no threshold adotado, o que gera um volume considerável de falsos positivos. Além disso, a curva de calibração (Brier Score de 0.1807) indicou que o modelo tende a ser conservador, subestimando ligeiramente a probabilidade real em faixas de risco muito elevado. Outra limitação é a natureza dos dados, que são autorrelatados e podem conter vieses de memória dos participantes. - Sugestões para Trabalhos Futuros: Para a evolução desta pesquisa, sugere-se: . Integração de Dados Biométricos: Incluir dados laboratoriais diretos (como HbA1c ou glicemia de jejum) para reduzir o volume de falsos positivos; . Análise de Séries Temporais: Utilizar dados longitudinais para prever não apenas o estado atual, mas a probabilidade de desenvolvimento da doença em um horizonte de 5 a 10 anos; . Refinamento de Calibração: Implementar técnicas de calibração de Isotonic Regression ou Platt Scaling para alinhar as probabilidades previstas à frequência real observada.