


Ferramenta de Suporte à Decisão Clínica: Predição de Risco de Diabetes

Uma abordagem de Machine Learning
(LGBM) focada em Saúde Pública e Triagem
Preventiva de Alta Sensibilidade.



FONTE DE DADOS

CDC Health Indicators

VOLUME

253.680 Registros

MODELO

LightGBM (Tuned)

STATUS

Pronto para Deploy/Triagem

Contexto e Missão: Da Predição à Decisão Clínica

O Desafio: O diabetes mellitus é uma epidemia global caracterizada por altos custos de complicações de longo prazo e subnotificação significativa de casos iniciais.

A Oportunidade: Utilizar um dataset robusto do CDC (250k+ amostras) para transformar dados demográficos e de estilo de vida em um escore de risco quantitativo.

Callout Box

Insight: Este projeto não é apenas um classificador binário, mas uma ferramenta de triagem projetada para atuar **antes** do agravamento clínico.



Dados Brutos (CDC)



Algoritmo (LGBM)




Alerta Precoce (Triagem)

A Matéria-Prima: Dados do CDC e a 'Tropicalização' Socioeconômica

Fonte: CDC Diabetes Health Indicators. Variáveis comportamentais, comportamentais, metabólicas e socioeconômicas.

Metodologia (Income): A variável de renda do CDC (faixas 1-8) foi tratada via One-Hot Encoding para mapear não-linearidades.

Adaptação Brasil (FGV): Transposição das faixas de renda para o contexto de gestão local, permitindo visualizar o impacto da vulnerabilidade social na doença.



Protocolo de Segurança: Mitigação de Data Leakage

Garantindo que o modelo identifique causas, e não consequências.

O Problema:



Variáveis como MentHlth e PhysHlth apresentaram alta correlação com o alvo.

Diagnóstico: Estas variáveis atuam como "sintomas tardios" ou consequências diretas do diabetes já estabelecido.


Ação: Remoção cirúrgica do dataset de treino.

Resultado: O modelo aprende fatores de risco reais (Metabólicos e Estilo de Vida), aplicável a pacientes assintomáticos.

Correlation Matrix



Seleção do Modelo: A Vitória do LightGBM



Desempenho em Desbalanceamento

Melhor generalização na classe minoritária (positivos).


Eficiência de Processamento

Otimizado para grandes volumes (250k+ registros).

Recall Superior

Capacidade crítica de não ignorar casos positivos.

O Coração da Estratégia: Threshold Clínico de 0.25



A Decisão:

Deslocamento do ponto de corte de 50% para 25%.


Lógica Médica:

Em saúde pública, o custo de não tratar um doente (Falso Negativo) é superior ao custo de testar um saudável (Falso Positivo).

Resultado:

O modelo torna-se propositalmente 'hipersensível'.

Análise de Impacto: A Economia dos Falsos Positivos



Sensibilidade (Recall):

94.89%

Merriweather

Precisão:


~23%

Merriweather

Managerial Insight

Analogia: O modelo funciona como uma 'rede de pesca fina'. Ele retém todos os peixes, mesmo que venha areia junto. O exame de sangue confirmatório (barato) separa a areia; o modelo garante que o peixe não escape.

Confiabilidade: O Modelo é Honesto?




Brier Score: 0.1820

Interpretação: A curva abaixo da diagonal indica que o modelo é conservador. Quando prevê risco, a realidade tende a ser ligeiramente menor, mas a ordenação do risco é consistente.


Conclusão: Excelente ferramenta para 'ranqueamento' de filas de atendimento (Triage).

Interpretabilidade Clínica (SHAP): Os 3 Vetores de Risco



Transparência: O modelo não é uma Caixa Preta. Ele valida hipóteses médicas conhecidas.

O Ponto de Virada: Deep Dive no IMC (BMI)



Insight: Abaixo de 25, o IMC atua como fator de proteção. Acima de 25, contribui positivamente para a predição, crescendo até um platô na obesidade mórbida.

Personificação do Risco: Estudo de Casos

Uma análise comparativa utilizando Force Plots para ilustrar como diferentes fatores clínicos contribuem para o risco individual.

Paciente A: A Tempestade Perfeita (Risco ~93%)



O modelo soma vetores metabólicos e comportamentais para emitir alerta vermelho. A combinação de obesidade mórbida, hipertensão e saúde geral autopercebida como ruim cria um efeito cumulativo devastador, empurrando a predição de risco para um nível extremo.

Paciente B: O Perfil Protegido (Risco ~1%)



A ausência de doença atua como força negativa, reduzindo o risco base. O índice de massa corporal saudável, a juventude e a falta de condições pré-existentes combinam-se para proteger o paciente, mantendo a predição de risco em um nível mínimo.

Sumário Executivo: Custo-Benefício da Triagem


Por que implementar agora?

Cenário Atual (Passivo)	Cenário Modelo (Triagem Ativa)
	
• Diagnóstico Tardio • Complicações Caras (Amputação, Diálise) • Custo Humano Elevado	• Identificação Precoce (Recall 95%) • Custo Operacional Marginal (Exames simples) • Prevenção de Crônicos

ROI: O custo de processar Falsos Positivos é marginal comparado à economia gerada pela prevenção de um único caso de complicações crônicas.

Implementação imediata como "Primeira Barreira" em Unidades Básicas de Saúde (UBS).

Limitações e Próximos Passos: O Caminho para o HbA1c



Uma Ferramenta Vital para a Saúde Preventiva

Este modelo não substitui o médico, mas garante que o paciente certo chegue ao consultório pro antes que seja tarde demais.

Iniciar Piloto de Triagem →